

Trabajo Práctico 3: Data-Centered Design

Materia: 72.75 Aprendizaje Automático (Machine Learning)

Fecha de defensa: 10/06/26

En este trabajo práctico se compararán estrategias model-centered y data-centered para resolver un problema de clasificación supervisada. El objetivo principal es analizar cómo la calidad, representación y selección de los datos puede impactar el rendimiento de un sistema de Machine Learning tanto o más que la elección del modelo.

La presentación durará 15 minutos + 10 minutos de preguntas.

*mandar la presentación, el predictor y el código 24 horas antes de la clase en la que se presentará el TP

0. Dataset

Para este trabajo se utilizará un dataset relacionado con reservas de infraestructura GPU en un entorno de cómputo distribuido. El objetivo es predecir si una reserva será cancelada antes de su ejecución (`canceled_job`).

El dataset contiene información relacionada con características temporales de la reserva, tipo de recursos solicitados, historial del cliente, duración y complejidad del workload y características económicas y contractuales de la reserva.

Además del dataset principal, durante el trabajo práctico podrán estar disponibles datasets adicionales correspondientes a cohortes específicas de datos (explicado más adelante).

El dataset principal pueden encontrarlo dentro de la carpeta Datasets en campus, con el nombre de "gpu_resource_reservations".

**Para más información sobre las variables del dataset, ver páginas 4 y 5 de este documento.*

1. Preprocesamiento y análisis exploratorio

Aunque no es el foco principal del TP, se valorará positivamente que se apliquen (y mencionen en la presentación) técnicas básicas vistas previamente de:

- limpieza de datos,
- tratamiento de missing values,
- encoding de variables categóricas,
- escalado,
- análisis exploratorio,
- y análisis de cohortes o subgrupos.
- Pueden tomar cualquier decisión sobre los datos, como eliminar/seleccionar alguna feature o datos, pero justifiquen la decisión

Además, recuerda realizar la división de datos entre entrenamiento y test antes de aplicar cualquier técnica que pueda producir data leakage.

2. Model-centered Machine Learning

2.1 Clasificadores - Establecimiento del baseline

Implementar (usando Scikit-learn) al menos uno de los clasificadores vistos en clase y hacer una breve calibración de hiperparámetros para establecer un clasificador baseline razonable.

2.2 Validación cruzada

Para la evaluación de estos clasificadores, implementar un esquema de k-fold cross-validation utilizando únicamente el conjunto de entrenamiento.

2.3 Métricas

Selecciona dos métricas vistas en clase y justifica su elección.

Utiliza estas métricas para:

- comparar modelos,
- seleccionar hiperparámetros,
- y tomar decisiones sobre el modelo baseline final.

3. Error analysis y enfoque data-centered

3.1 Análisis de errores

Utilizando el modelo baseline que consideren más adecuado en base a los análisis anteriores, realizar un análisis detallado de errores.

Se espera:

- definición de cohortes relevantes en los datos (en particular de *client_type*, *service_tier*, *reserved_gpu_type*)
- análisis por cohortes o subgrupos,
- análisis de falsos positivos y falsos negativos,
- identificación de regiones problemáticas del dataset,

3.2 Curvas de aprendizaje

Analizar cómo evoluciona el rendimiento del modelo al aumentar la cantidad de datos de entrenamiento.

Discutir:

- si el sistema parece limitado por el modelo o por los datos,
- y si obtener más datos podría mejorar significativamente el rendimiento.

3.3 Estrategia data-centered

A partir del análisis de errores del apartado 3.1, seleccionar una cohorte o subconjunto problemático de datos y justificar por qué consideran prioritario intervenir sobre él.

Se deberá discutir:

- frecuencia del problema,
- impacto operativo,
- y posibles causas del mal rendimiento
- propuesta de siguientes pasos y posibles áreas o estrategias para mejorar

3.4 Adquisición de datos y data augmentation

Se proporcionarán datasets adicionales correspondientes a distintas cohortes de datos.
(manden mail para pedir los datos extras de ese cohorte)

Cada grupo deberá decidir:

- qué datos adicionales incorporar (solo uno!),
- cuánto incorporar,
- y justificar por qué esperan que eso mejore el sistema.

Además, comparar esta estrategia con una técnica de data augmentation o synthetic data para datasets tabulares (por ejemplo SMOTE). Es decir, en lugar de añadir el nuevo dataset, generar datos de ese cohorte elegido utilizando SMOTE.

Discutir:

- ventajas y limitaciones de datos reales vs sintéticos,
- posibles riesgos,
- y situaciones donde estas estrategias pueden empeorar el rendimiento.

4. Modelo final

Seleccionar la estrategia final que consideren más adecuada:

- modelo,
- hiperparámetros,
- y modificaciones data-centered aplicadas.

Evaluar el sistema final y estimar cuál es la performance esperada en datos nuevos.

Crear y **submitir (por mail) la función predictora del grupo, con nombre: predictor_v1_Grupo_X(), donde X es el número de su grupo**

Discutir especialmente qué cambios produjeron mayores mejoras y si esas mejoras fueron globales o específicas de ciertos subgrupos.

5. Conclusiones

Reflexionar sobre diferencias entre enfoques model-centered y data-centered, qué funcionó mejor y por qué, limitaciones del sistema, posibles fuentes de sesgo o leakage y futuras mejoras posibles.

Información sobre las variables incluidas en el Dataset:

Feature	Descripción
<code>datacenter</code>	Centro de cómputo donde se asignará la reserva GPU.
<code>canceled_job</code>	Variable objetivo. Indica si la reserva fue cancelada antes de ejecutarse.
<code>hours_before_execution</code>	Horas entre la creación de la reserva y el inicio programado de ejecución.
<code>request_month</code>	Mes en el que se realizó la solicitud.
<code>request_week</code>	Semana del año en la que se realizó la solicitud.
<code>request_day</code>	Día del mes en el que se realizó la solicitud.
<code>peak_gpu_hours</code>	Horas GPU reservadas en períodos de alta demanda.
<code>offpeak_gpu_hours</code>	Horas GPU reservadas en períodos de baja demanda.
<code>num_primary_processes</code>	Número de procesos principales asociados al workload.
<code>num_auxiliary_processes</code>	Número de procesos auxiliares asociados al workload.
<code>num_background_processes</code>	Número de procesos secundarios o de mantenimiento asociados al workload.
<code>service_tier</code>	Nivel de servicio contratado para la reserva.
<code>client_type</code>	Tipo de cliente que realiza la solicitud.
<code>request_channel</code>	Canal utilizado para realizar la reserva.
<code>returning_client</code>	Indica si el cliente ya había utilizado previamente la plataforma.
<code>previous_job_cancellations</code>	Cantidad de reservas canceladas previamente por el cliente.
<code>successful_previous_jobs</code>	Cantidad de reservas completadas exitosamente por el cliente.
<code>reserved_gpu_type</code>	Tipo de GPU solicitado originalmente.

assigned_gpu_type	Tipo de GPU finalmente asignado para la ejecución.
resource_modifications	Número de modificaciones realizadas sobre la reserva original.
reservation_commitment	Tipo de compromiso contractual asociado a la reserva.
queue_wait_time	Tiempo de espera en cola antes de la asignación definitiva de recursos.
workload_profile	Perfil general o tipo de workload solicitado.
estimated_cost_per_hour	Costo estimado por hora de la reserva GPU.
reserved_storage_units	Cantidad de unidades de almacenamiento reservadas.
special_resource_requests	Número de solicitudes especiales asociadas a la reserva.
total_gpu_hours	Cantidad total de horas GPU reservadas.
total_processes	Número total de procesos involucrados en la ejecución.
high_value_client	Indica si el cliente es considerado estratégico o prioritario.